COMPEON
Das Finanzportal für den Mittelstand

Seminar Statistische Lernverfahren

Klassifikation von Rezensionstypen

Till Gräfenberg, Matthias Häußler, Alexander Kohlscheen, Michael Lau,
Tanja Niklas, Jonathan Schmitz

12. Dezember 2019

Inhaltsverzeichnis

Problemstellung

- Ziel: Klassifizierung von Reviews in folgende Typen

Texttyp	introvertiert	extrovertiert
emotional	stetig	initiativ
rational	gewissenhaft	dominant

- Gegeben: 439 bereits klassifizierte Reviews

Erstellen von Prädiktoren

- Klassifikation sollte durch verwendete Wörter geschehen
- Zurückführung auf Grundwörter notwendig
- Benutzung verschiedener Packages in `R` bzw. `Python` ermöglichte verschiedene Verfahren.

Erstellen von Prädiktoren

Stemming

- Durch Abschneiden von Prä-/In- und Suffixen und Ersetzen von Umlauten, Diphtongen etc. erzeugen von Wortstämmen.
- Eigene Implementierung nach Vorgabe von COMPEON in `R`
- Für Englische Sprache bereits vorgefertigte Tools z.B.
  - `porterstemmer` von `nltk` in Python
  - `snowballstemmer` von `nltk` in Python

Probleme:

- Unregelmäßigkeit von Verben im Deutschen
- Komposita

Erstellen von Prädiktoren

Lemmatisierung

- Alternative: Zurückführung auf grammatikalische Grundformen
- Erfordert vorgefertigte Packages z.B.
  - `SpaCy` in Python
  - `nltk` in Python
- Diese lieferten zusätzlich Informationen über die Wortart
- Auch hier für Englische Sprache ausgereifter als die deutsche Alternative

Erstellen von Prädiktoren

Filterung der Prädikatoren, weitere

- Nach Erstellung der Grundwörter konnte gefiltert werden, welche Wörter häufig auftraten
- Denkbare Filtermethoden:
  - Nur Wörter, die mind. n Mal aufgetaucht sind
  - Nur Wörter, die in mind. $p\%$ der Reviews verwendet wurden
- Anschließend Erstellung einer binären Document-Term-Matrix, die kodiert, welche Grundwörter in welchen Reviews auftauchten
- Alternative: PCA um aussagekräftige „Wörterachsen“ zu bestimmen.

Erstellen von Prädiktoren

PCA - Principal Component Analysis

Ziel: Dimensionsreduktion

Idee: Suche die Datenachsen, auf denen die Varianz am größten ist

Verfahren:

- Sei X die DT-Matrix (Spaltenmittelwerte $= 0$)
- Bestimme die Kovarianzmatrix $Cov = X^T X$
- Bestimme die Eigenwerte λ_i und Eigenvektoren v_i von Cov
- Sei $V = (v_1|v_2|...)$
- Transformiere die Daten zu $\hat{X} = XV$

Problem: Die Resultate verlieren an Interpretierbarkeit

Erstellen von Prädiktoren

PCA - Principal Component Analysis

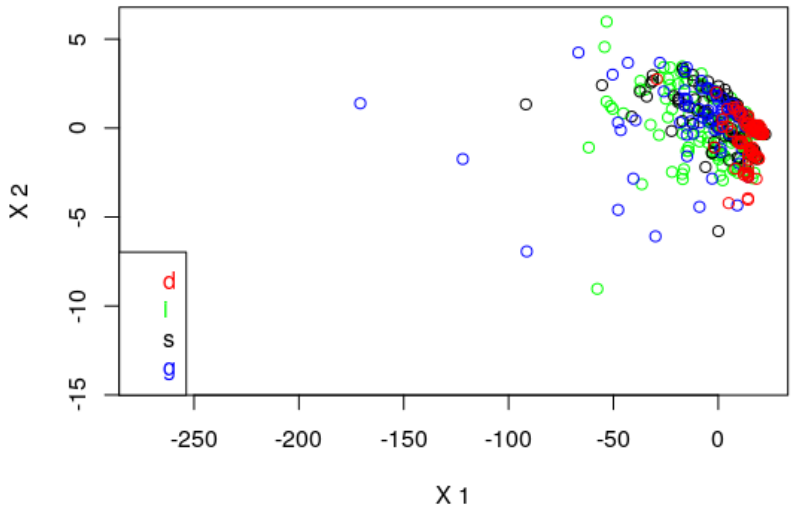

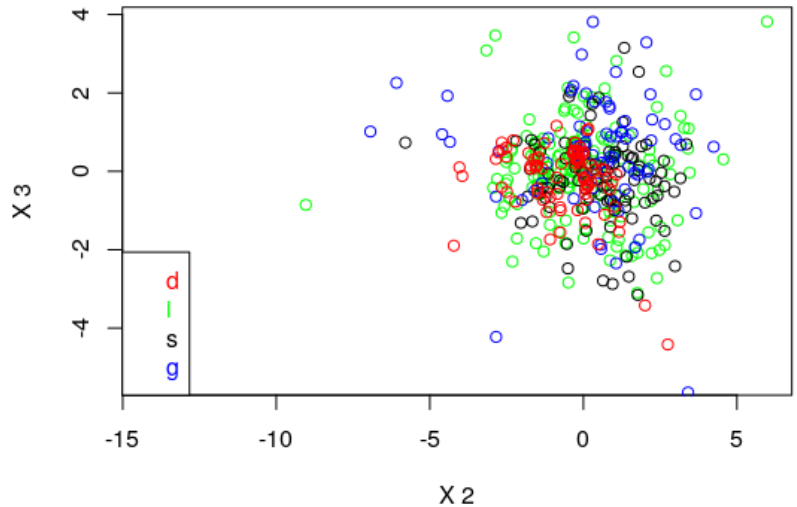

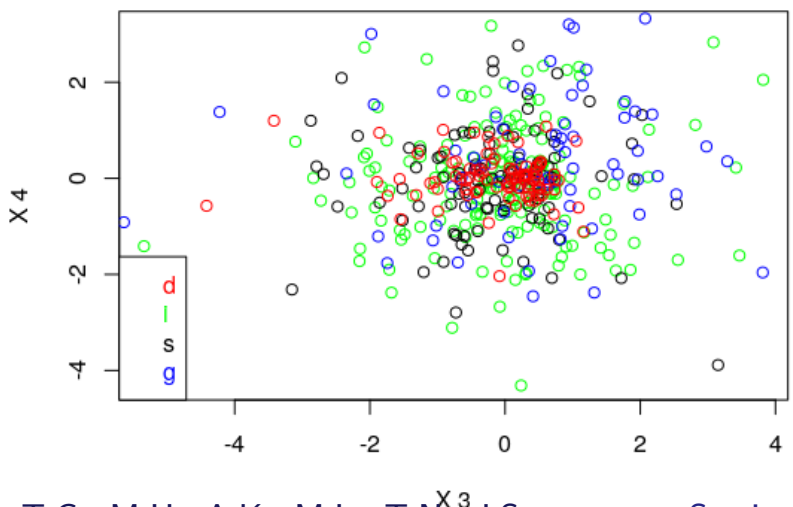

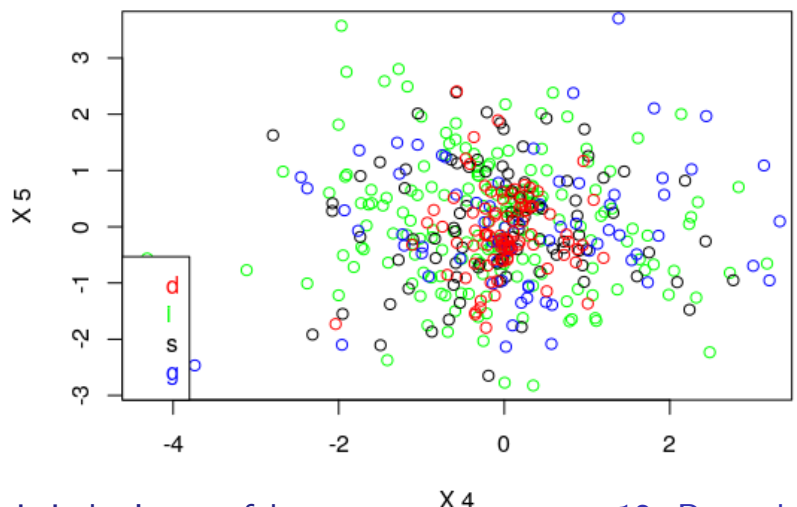

Erstellen von Prädiktoren

PCA - Principal Component Analysis

Fazit:

- Die Dominanten Reviews haben eine geringere Varianz
- keine erkennbaren Gruppen
- Mittelwerte der Gruppen sind ähnlich

Das Verfahren liefert keine besseren Ergebnisse.

Analysemethoden

Naive Bayes

- Das Naive Bayes Verfahren fußt auf dem Bayes Theorem

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)}$$

bzw. für unabhängige Prädiktoren $x_1, ..., x_n$ als

$$p(y|x_1, ..., x_n) = \frac{p(x_1|y) \cdots p(x_n|y)p(y)}{p(x_1, ..., x_n)} \propto p(x_1|y) \cdots p(x_n|y)p(y).$$

- Durch Schätzen von $p(y)$ und $p(x_i|y)$ (für die Reviewtypen y) durch die relativen Häufigkeiten, können wir dann Klassifikationen durchführen als

$$\hat{y} = \text{argmax}_y \, p(y) \prod_{i=1}^{n} p(x_i|y).$$

Analysemethoden

Naive Bayes

- Durchführung war in `R` mit dem Package `caret`, über `Python` mit `sklearn` möglich. Mit letzterem haben wir jeweils die deutschen und englischen Reviews klassifiziert.

- Dieses Vorgehen zeigte nur wenig bessere Ergebnisse als eine einheitliche Zuweisung.

(Bester) Naive Bayes, `R`, Wortaufkommen > 20

	D	G	I	S	Acc.	Prec.	Recall	F1
Dominant	14	2	8	1		0,412	0,778	0,538
Gewissenhaft	0	0	0	0		n.d.	0	n.d.
Initiativ	4	11	28	17		0,467	0,778	0,583
Stetig	0	1	0	0		0	0	0
Total					0,488	n.d.	0,389	n.d.

Naive Bayes, `Python`, Wortvorkommen in mind. 1% der Texte, Lemmatisierung mit spacy, Englisch

	D	G	I	S	Acc.	Prec.	Recall	F1
Dominant	13	4	12	4		0,394	0,722	0,51
Gewissenhaft	0	3	3	0		0,5	0,214	0,3
Initiativ	4	5	16	11		0,444	0,444	0,444
Stetig	1	2	5	3		0,273	0,167	0,207
Total					0,407	0,402	0,387	0,365

Naive Bayes, `Python`, Wortvorkommen in mind. 1% der Texte, Lemmatisierung mit spacy, Deutsch

	D	G	I	S	Acc.	Prec.	Recall	F1
Dominant	16	2	13	2		0,593	0,889	0,711
Gewissenhaft	0	5	4	1		0,5	0,357	0,417
Initiativ	2	5	16	13		0,444	0,444	0,444
Stetig	0	2	3	2		0,286	0,111	0,16
Total					0,453	0,456	0,450	0,433

Analysemathoden

weitere Anpassungen und Modelle

Mit Naive Bayes und den Wortarten als Prädiktoren lässt sich zuverlässig voraussagen, ob eine Person extrovertiert ist:

	extrovertiert	introvertiert
extrovertiert	30	5
introvertiert	24	27

Idee:
Nutze die Vorhersage dieses Modells um ein neues Modell anzupassen.

Analysemathoden

weitere Anpassungen und Modelle

Random Forest

	D	G	I	S
D	14	2	8	1
G	1	4	1	0
I	3	7	25	15
S	0	1	2	2

Random Forest mit Naive Bayes

	D	G	I	S
D	15	2	9	1
G	0	4	1	1
I	3	8	24	13
S	0	0	2	3

Das modifizierte Verfahren liefert im Schnitt keine besseren Ergebnisse

Analysemethoden

Entscheidungsbaum

- Teilt in Klassen auf
- Wahr oder Falsch Entscheidungen
- Jedes Blatt hat genau eine Klasse
- Verwende `rpart`

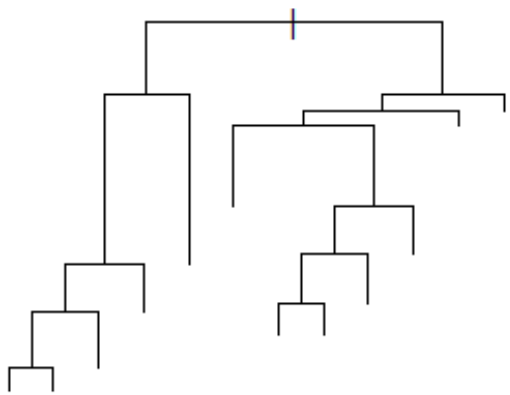

Resultate Entscheidungsbaum, R, mind. 20 mal Wörter

	Dominant	Gewissenhaft	Initiativ	Stetig
Dominant	14	3	9	1
Gewissenhaft	0	3	5	5
Initiativ	2	4	19	5
Stetig	2	4	3	7

Resultate Entscheidungsbaum, R, mind. 20 mal Wörter

	Precision	Recall	F1
Dominant	51,8%	77,7%	62,1%
Gewissenhaft	23,0%	21,4%	22,1%
Initiativ	63,3%	52,7%	57,5%
Stetig	43,7%	38,8%	41,1%
Macro	45,4%	47,6%	45,4%

Resultate Entscheidungsbaum, Python, mind. in 1% der Texte, englisch

	Dominant	Gewissenhaft	Initiativ	Stetig
Dominant	9	4	12	5
Gewissenhaft	2	3	4	2
Initiativ	5	5	12	8
Stetig	2	2	8	3

Resultate Entscheidungsbaum, Python, mind. in 1% der Texte, englisch

	Precision	Recall	F1
Dominant	30,0%	50,0%	37,5%
Gewissenhaft	27,2%	21,4%	23,9%
Initiativ	40,0%	33,3%	36,3%
Stetig	20,0%	16,6%	18,1%
Macro	29,3%	30,3%	28,9%

Resultate Entscheidungsbaum, Python, mind. in 1% der Texte, deutsch

	Dominant	Gewissenhaft	Initiativ	Stetig
Dominant	13	4	16	1
Gewissenhaft	2	4	1	3
Initiativ	3	5	13	7
Stetig	0	1	6	7

Resultate Entscheidungsbaum, Python, mind. in 1% der Texte, deutsch

	Precision	Recall	F1
Dominant	38,2%	72,2%	49,9%
Gewissenhaft	40,0%	28,5%	33,2%
Initiativ	46,4%	36,1%	40,6%
Stetig	50,0%	38,8%	43,6%
Macro	43,6%	43,9%	41,8%

Analysemethoden

Random Forest

- Entscheidungsbaum nicht beste Option
  - gut für Trainingsdaten
  - nicht flexibel
  - Probleme mit neuen Datensätzen
- Generiere neue Testdaten durch Wählen mit Zurücklegen
- Erzeuge Entscheidungsbaum
- Generiere so viele Entscheidungsbäume
- Entscheidung durch Mehrheitsentscheidung
- `R randomForest` 2000 Bäume

Resultate Random Forest, R, mind. 20 mal Wörter

	Dominant	Gewissenhaft	Initiativ	Stetig
Dominant	14	2	10	0
Gewissenhaft	2	4	0	1
Initiativ	2	7	25	14
Stetig	0	1	1	3

Resultate Random Forest, R, mind. 20 mal Wörter

	Precision	Recall	F1
Dominant	53,8%	77,7%	63,5%
Gewissenhaft	57,1%	28,5%	28,0%
Initiativ	52,0%	69,4%	59,4%
Stetig	60,0%	16,6%	26,0%
Macro	55,7%	48,0%	44,2%

Resultate Random Forest, Python, mind. in 1% der Texte, englisch

	Dominant	Gewissenhaft	Initiativ	Stetig
Dominant	16	4	14	4
Gewissenhaft	0	6	2	1
Initiativ	1	4	16	9
Stetig	1	0	4	4

Resultate Random Forest, Python, mind. in 1% der Texte, englisch

	Precision	Recall	F1
Dominant	42,1%	88,8%	57,1%
Gewissenhaft	66,6%	42,8%	52,1%
Initiativ	53,3%	44,4%	48,4%
Stetig	44,4%	22,2%	29,6%
Macro	51,6%	49,5%	46,8%

Resultate Random Forest, Python, mind. in 1% der Texte, deutsch

	Dominant	Gewissenhaft	Initiativ	Stetig
Dominant	15	4	15	2
Gewissenhaft	0	3	4	3
Initiativ	2	4	15	9
Stetig	1	3	2	4

Resultate Random Forest, Python, mind. in 1% der Texte, deutsch

	Precision	Recall	F1
Dominant	41,6%	83,3%	55,4%
Gewissenhaft	30,0%	21,4%	24,9%
Initiativ	50,0%	41,6%	45,4%
Stetig	40,0%	22,2%	28,5%
Macro	40,4%	42,1%	38,5%

Analysemethoden

Support Vector Machine

- Versucht Entscheidungsgrenze (Hyperebene) zu finden, die die Distanz der nächsten Datenpunkte jeder Klasse zu ihr maximiert

- Diese nächsten Datenpunkte sind die *Support Vectors*

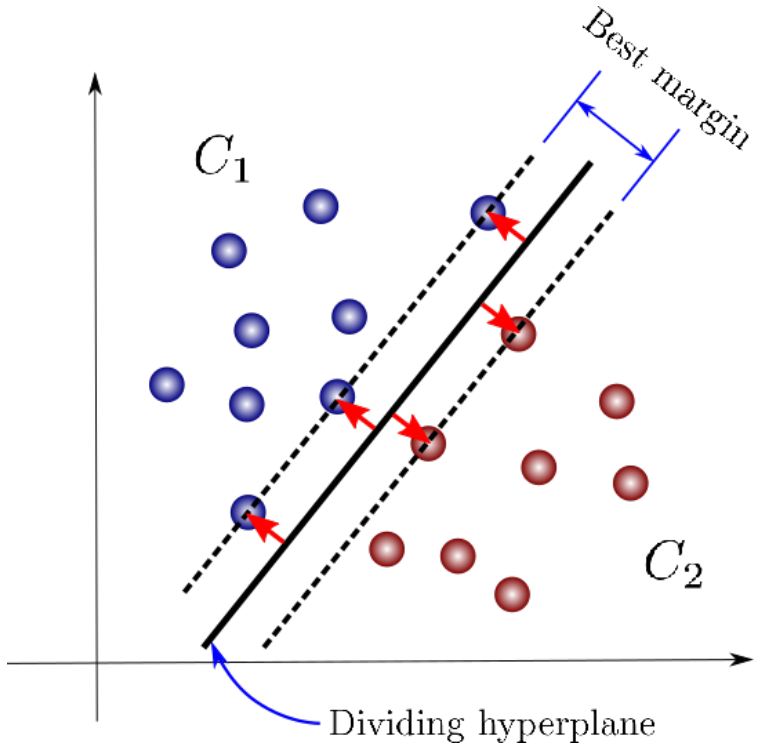

Quelle: `https://towardsdatascience.com/support-vector-machines-for-classification-fc7c1565e3`

Analysemethoden

Support Vector Machine

- Verschiedene Kerne (Funktionen) um dem Separierungsproblem gerecht zu werden
- Kerne projizieren nicht-linear separierbare Daten niedrigerer Dimensionen auf linear-separierbare Daten höherer Dimensionen
- Vier häufig verwendete Kerne:
  - Linear
  - Polynomiell
  - Radial
  - Sigmoidal (Tangens hyperbolicus)
- In `R` mit `e1071` und in Python mit `sklearn`

Resultate Support Vector Machine, R, mind. 10 mal Wörter, Radialer Kern

	D	G	I	S	Acc.	Prec.	Recall	F1
Dominant	14	3	8	1		0,538	0,778	0,636
Gewissenhaft	0	1	1	0		0,500	0,071	0,163
Initiativ	4	10	27	14		0,570	0,750	0,419
Stetig	0	0	0	3		1,000	0,167	0,209
Total					0,5233	0,632	0,441	0,410

Resultate Support Vector Machine, Python, Englisch, mind. 20 mal Wörter, Sigmoid Kern

	D	G	I	S	Acc.	Prec.	Recall	F1
Dominant	14	2	9	1		0,54	0,78	0,64
Gewissenhaft	0	5	4	1		0,50	0,36	0,42
Initiativ	3	5	19	13		0,47	0,53	0,50
Stetig	1	2	4	3		0,30	0,17	0,21
Total					0,477	0,45	0,46	0,44

Schwierigkeiten

- Keine eindeutige Klassifikation
  - Auch für Menschen nicht eindeutig
  - Teilweise sehr geringe Unterschiede zwischen den Typen
- Stemming nicht unbedingt eindeutig
  - Unregelmäßigkeit von Verben im Deutschen
  - Komposita
- Geringe Zahl an Trainingsdaten
- Unbalanciertes Studiendesign
- Representativität
  - Introvertierte Kunden schreiben weniger häufig Reviews
  - Nur positive Bewertungen lagen vor